




Detección de Tumores Cerebrales con YOLOv8

Proyecto Final

Integrates:

Moctezuma Mónico Sandra Bianey

Morales Calvario Wendy Lizeth

YOLOv8

Deep Learning

Imágenes MRI

Objetivo y Planteamiento del Problema

El Planteamiento del Problema

El diagnóstico de tumores cerebrales es un proceso complejo y tardado que depende de la experiencia del médico radiólogo.

Un error o retraso puede tener consecuencias graves para el paciente.

Problemas actuales:

- Proceso lento y costoso
- Depende 100% del experto
- Escasez de radiólogos

Objetivo General

Desarrollar un modelo de IA con YOLOv8 capaz de detectar tumores cerebrales en imágenes MRI, para usarse como herramienta de apoyo médico.

¿Para qué sirve?

- Apoyo al diagnóstico médico
- Segunda opinión automatizada
- Detección temprana de tumores
- Zonas sin especialistas médicos

Dataset y Etiquetado

878

Imágenes
anotadas

2

Clases a
detectar

70/20/10

Train / Val
/ Test %

Nombre	Brain Tumor Detection Dataset
Fuente	Kaggle — Ultralytics (ultralytics/brain-tumor)
Formato	YOLOv8 — imágenes .jpg + etiquetas .txt con bounding boxes
Clase 0	negative — imagen MRI sin tumor cerebral
Clase 1	positive — imagen MRI con tumor cerebral presente
Limpieza	Ya venía etiquetado. No se requirió limpieza adicional.

Entrenamiento del Modelo YOLOv8

YOLOv8n

NANO

“n” = nano (pequeño)

El más pequeño y rápido. Ideal cuando necesitas velocidad y usas pocos recursos.

YOLOv8s

SMALL

“s” = small (pequeño)

Tamaño medio. Buen balance entre velocidad y precisión. El ganador en este proyecto.

YOLOv8m

MEDIUM

“m” = medium (mediano)

El más grande. Mayor capacidad pero más lento. Necesita más datos para rendir bien.

Hiperparámetros usados en los 3 modelos:

Epochs: 50 | Batch: 16 | Tamaño imagen: 640×640 px | GPU: T4 (Google Colab)



Métricas y Resultados Comparativos


Métrica	YOLOv8n (Nano)	YOLOv8s (Small)	YOLOv8m (Medium)
mAP@50	0.709 (71%)	0.721 (72%)	0.577 (58%)
Precisión máx.	0.97 (97%)	0.99 (0.99%)	0.99 (0.99%)
Recall máx.	0.97 (97%)	0.98 (98%)	0.95 (95%)
F1 Score	0.68	0.68	0.62
Detectó tumores	55 correctos	65 correctos	54 correctos
Confianza inferencia	69%	52%	52%

Análisis de Gráficas — F1 Score y Precision-Recall


F1-Confidence Curve

Muestra el balance entre precisión y recall. El punto más alto de la curva indica el mejor umbral de confianza para el modelo. Nano y Small empataron en 0.68, mientras Medium bajó a 0.62.


Nano



Small




Medium




Precision-Recall Curve (mAP@50)

Muestra la calificación general del modelo. Entre más grande el área bajo la curva, mejor detecta. Small obtuvo el mejor mAP (0.721), seguido de Nano (0.709). Medium fue el peor (0.577).


Nano



Small




Medium



Matriz de Confusión — ¿Qué tan bien clasificó cada modelo?

¿Qué es esta gráfica? Muestra los aciertos y errores del modelo. Los cuadros oscuros en diagonal = aciertos (bien detectado). Los claros = errores (se confundió).

Nano




Sin tumor correcto: 52
Con tumor correcto: 55
Errores totales: 64

Small



Sin tumor correcto: 45
Con tumor correcto: 65
Errores totales: 67

Medium




Sin tumor correcto: 36
Con tumor correcto: 74
Errores totales: 84

Curvas de Entrenamiento — ¿Cómo aprendió cada modelo?


¿Qué se ve aquí? Las líneas que bajan = el error disminuye (el modelo aprende). Las que suben = la precisión mejora. Si las curvas son suaves = modelo estable. Si tienen picos = inestable.

Nano




Curvas suaves y estables. Aprendió bien en las 50 épocas.

Small



Las curvas más limpias de los 3. Aprendizaje muy estable.

Medium




Tuvo picos bruscos en validación. Señal de inestabilidad.

Implementación Funcional — Prueba con Imagen Real

Se probó el modelo con una imagen MRI que nunca había visto. El recuadro azul marca la zona donde detectó el tumor. El número es la confianza del modelo.

Nano




Clase detectada: **1 (positive = tumor)**

Confianza:

69%

Small




Clase detectada: **1 (positive = tumor)**

Confianza:

52%

Medium



Clase detectada: **1 (positive = tumor)**

Confianza:

52%

Conclusiones

Mejor modelo general

YOLOv8s (Small)
mAP@50: 0.721 — el más alto
Curvas más estables

Mejor velocidad

YOLOv8n (Nano)
Mismos resultados F1 (0.68)
Mayor confianza: 69%

Peor rendimiento

YOLOv8m (Medium)
Dataset pequeño = sobreajuste
Más grande ≠ siempre mejor

Impacto en Ingeniería en Sistemas Computacionales

Este proyecto demuestra habilidades reales en IA, Visión por Computadora, Cómputo en la Nube y manejo de datos — áreas clave del mercado laboral en IA e investigación médica.

Metodología del Proyecto



Posibles Errores del Modelo y Futuras Mejoras

Posibles Errores del Modelo

Falso Negativo

Hay tumor pero el modelo dice que no. El paciente no recibiría tratamiento.

Falso Positivo

No hay tumor pero el modelo dice que sí. Genera alarma innecesaria y más estudios.

Sobreajuste (Overfitting)

El modelo aprendió el dataset de memoria pero falla con imágenes nuevas. Pasó con YOLOv8m.

Futuras Mejoras

Más imágenes en el dataset

Con más de 5,000 imágenes el modelo aprendería mejor y reduciría errores.

Aumento de datos

Rotar, voltear y ajustar brillo en las imágenes para que el modelo sea más robusto.

Modelo en producción

Subir el modelo a una app web o API para que cualquier médico lo use en el navegador.