



Tecnológico Nacional de México **Campus Chilpancingo**



Ingeniería en sistemas Computacionales

Materia:
Inteligencia Artificial

Actividad
YOLO para Clasificación y Segmentación de Residuos

Alumna :
Sandra Bianey Moctezuma Mónico

Grupo
S8A

Docente:
Yanet Evangelista Alcocer

1. Introducción

En esta práctica se entrenaron dos modelos de inteligencia artificial usando YOLO (You Only Look Once) con el objetivo de reconocer y clasificar residuos en imágenes. Se trabajó con dos tareas distintas: clasificación e segmentación de instancias.

Para la clasificación se utilizó el dataset TrashNet, que contiene imágenes de residuos organizadas por categoría. Para la segmentación se utilizó TACO (Trash Annotations in Context), un dataset con imágenes de basura en ambientes reales que incluye anotaciones de las formas exactas de cada objeto.

Las clases utilizadas en ambos modelos fueron:

- Plástico
- Papel / Cartón
- Metal
- Vidrio
- Basura general

2. Preparación de los Datasets

2.1 Dataset de Clasificación — TrashNet

Las imágenes de TrashNet se organizaron en carpetas por clase y se dividieron en tres conjuntos:

Conjunto	Plástico	Papel/Cartón	Metal	Vidrio	Basura General
Entrenamiento (70%)	337	697	287	350	95
Validación (20%)	96	198	82	100	27
Prueba (10%)	49	102	41	51	15

2.2 Dataset de Segmentación — TACO

TACO contiene fotos de basura en entornos reales. Las anotaciones originales en formato COCO se convirtieron al formato de polígonos normalizados que requiere YOLO. Se usaron 800 imágenes en total:

Conjunto	Imágenes
Entrenamiento	500
Validación	143
Prueba	72

Distribución de objetos por clase: Plástico 1,037 | Basura general 548 | Metal 305 | Papel/Cartón 212 | Vidrio 50

3. Entrenamiento de los Modelos

3.1 Modelo de Clasificación

Se entrenó el modelo yolo11n-cls.pt durante 20 épocas con imágenes de 224x224 píxeles. El modelo fue mejorando progresivamente su precisión en cada época, alcanzando al final los siguientes resultados:


- Top-1 Accuracy final: 0.932 (93.2%)
- Top-5 Accuracy: 100%
- Tiempo total de entrenamiento: 0.090 horas

3.2 Modelo de Segmentación

Se entrenó el modelo yolo11n-seg.pt durante 30 épocas con imágenes de 640x640 píxeles. Al ser una tarea más compleja, los resultados son más bajos que en clasificación pero esperados para un dataset pequeño:

- mAP50 promedio: 0.394
- mAP50-95 promedio: 0.202
- Precisión promedio: 0.381
- Recall promedio: 0.386
- Tiempo total de entrenamiento: 0.317 horas

4. Pruebas con Imágenes Nuevas



4.1 Prueba de Clasificación

Se tomó una imagen aleatoria del conjunto de prueba, correspondiente a la clase vidrio. El modelo predijo:

- Clase predicha: vidrio
- Confianza: 1.00 (100%)
- Resultado: CORRECTO

4.2 Prueba de Segmentación

Se tomó una imagen aleatoria del conjunto de prueba. El modelo detectó y segmentó los siguientes objetos:

- 1 objeto de plástico
- 5 objetos de metal

El modelo dibujó máscaras sobre cada objeto identificado, mostrando su forma exacta dentro de la imagen.

5. Tabla Comparativa

Aspecto	Clasificación	Segmentación
Entrada	Imagen completa	Imagen con uno o varios objetos
Salida	Solo dice qué tipo de residuo es	Dice qué es, dónde está y dibuja su forma
Dificultad del dataset	Baja: solo carpetas por clase	Alta: requiere máscaras o polígonos
Utilidad con varios residuos	Limitada, puede confundirse	Alta, detecta y separa cada objeto
Precisión obtenida	93.2% (Top-1 Accuracy)	mAP50: 0.394
Tiempo de entrenamiento	0.090 horas (20 épocas)	0.317 horas (30 épocas)
Aplicación recomendada	Clasificación rápida y sencilla	Contenedor inteligente, robot reciclador

6. Análisis de Métricas

6.1 Métricas del modelo de clasificación

Top-1 Accuracy (0.932): Indica que el modelo clasificó correctamente el 93.2% de las imágenes de prueba en su primera predicción. Es una métrica muy importante porque refleja directamente si el modelo responde bien ante una imagen nueva.

Top-5 Accuracy (1.00): La clase correcta siempre apareció entre las 5 predicciones más probables del modelo. Esto confirma que el modelo no tiene confusiones graves entre clases.

Estas métricas son importantes porque muestran qué tan confiable es el modelo antes de usarlo en producción. Un modelo con 93% de precisión es suficientemente bueno para aplicaciones de clasificación de residuos a gran escala.

6.2 Métricas del modelo de segmentación

mAP50 (0.394): Mide qué tan bien el modelo detecta y dibuja las máscaras de los objetos. Un valor de 0.394 indica un desempeño moderado, lo cual es esperable dado el tamaño reducido del dataset (800 imágenes).

mAP50-95 (0.202): Versión más estricta del mAP que exige máscaras más precisas. El valor bajo indica que las máscaras no son perfectas pero sí funcionales para detectar la ubicación general de los objetos.

Precisión (0.381) y Recall (0.386): La precisión indica que de todos los objetos que el modelo detectó, el 38.1% eran correctos. El recall indica que el modelo encontró el 38.6% de todos los objetos reales presentes en las imágenes.

La clase con mejor desempeño fue el plástico (mAP50: 0.566), lo cual tiene sentido porque fue la clase con más ejemplos de entrenamiento (1,037 objetos). La clase con peor desempeño fue el vidrio (mAP50: 0.281), probablemente porque solo había 50 objetos en todo el dataset, lo que no es suficiente para que el modelo aprenda sus características visuales.

Estas métricas son fundamentales porque permiten identificar en qué clases falla el modelo y tomar decisiones: por ejemplo, recolectar más imágenes de vidrio para mejorar esa categoría específica.

7. Conclusión

En esta práctica pude comprobar de manera práctica la diferencia entre dos tareas fundamentales de visión por computadora aplicadas al reconocimiento de residuos.

El modelo de clasificación fue mucho más sencillo de preparar y entrenar, y obtuvo resultados excelentes (93.2% de precisión) porque la tarea es más simple: solo necesita decir qué tipo de residuo aparece en la foto. Sin embargo, tiene una limitación importante: si en la imagen hay varios tipos de basura al mismo tiempo, el modelo puede confundirse o solo reportar uno de ellos.

El modelo de segmentación fue más difícil de preparar porque requirió convertir las anotaciones de TACO al formato de YOLO, y también tardó más en entrenar. Sus resultados numéricos son más bajos, pero eso se explica principalmente por el tamaño reducido del dataset. La gran ventaja de este modelo es que no solo identifica qué es el residuo, sino que también lo localiza exactamente dentro de la imagen y dibuja su contorno. Esto lo hace mucho más útil para aplicaciones reales.

Para una aplicación como un contenedor inteligente de reciclaje o un brazo robótico que separe residuos, el modelo de segmentación sería claramente el más adecuado, porque permite saber qué es cada objeto, dónde está y cuál es su forma, información necesaria para manipularlo o clasificarlo físicamente.

Si tuviera que mejorar los modelos, recolectaría más imágenes de las clases con menos ejemplos, especialmente vidrio, y aumentaría el número de épocas de entrenamiento para que el modelo de segmentación tenga más tiempo de aprender los patrones visuales de cada tipo de residuo.